2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 35

Rojas, Lucas Nahuel

Rodriguez Giacomasso, Santiago

Vailati, Nahuel

1. Introducción

Origen y Naturaleza de los Datos: El conjunto de datos utilizado para este análisis proviene de la Encuesta de Desarrolladores 2025 (2025 Developer Survey) realizada por Stack Overflow, la cual se presenta como el informe definitivo sobre el estado del desarrollo de software a nivel global. En esta edición, correspondiente a su decimoquinto año, la organización logró recopilar más de 49.000 respuestas de individuos pertenecientes a 177 países. Según la publicación oficial, el objetivo primordial de esta encuesta es proporcionar una instantánea crucial sobre las necesidades de la comunidad, prestando especial atención a las herramientas y tecnologías que utilizan actualmente (con un nuevo enfoque en agentes de IA y LLMs) y aquellas sobre las que desean aprender más.

Análisis Estructural del Dataset y Resolución de Problemas: Estructuralmente, los datos provistos se dividen en dos archivos complementarios: un esquema (schema.csv) que funciona como diccionario de las preguntas y un archivo de resultados (results.csv) que contiene las respuestas reales.

Durante la exploración inicial, identificamos una discrepancia metodológica interesante: mientras que la documentación oficial indica que la encuesta consta de solo 62 preguntas, el diccionario de datos (schema.csv) es mucho más extenso, poseyendo 139 filas. Esta expansión estructural en la base de datos se debe a la arquitectura interna del instrumento de recolección. La plataforma no solo registra las 62 preguntas principales que percibe el usuario, sino que multiplica las filas en el *backend* para almacenar de forma independiente las ramificaciones condicionales, preguntas de control y cada una de las sub-preguntas a evaluar (identificadas con sq_id). Por ejemplo, una única pregunta oficial que solicite rankear múltiples opciones genera decenas de filas en el esquema, inflando el conteo total.

Asimismo, detectamos un desfasaje estructural producto de las limitaciones de los archivos planos (CSV). En el esquema original (schema.csv) existen preguntas de tipo Matriz (*Matrix*), como DevEnvs o AIAgentChallenges, donde el encuestado evaluó simultáneamente múltiples sub-opciones en una cuadrícula. Como la regla técnica de exportación exige que cada usuario ocupe exclusivamente una única fila en el dataset resultante, el sistema se ve obligado a desarmar estas matrices. En consecuencia, la plataforma concatena el identificador base de la matriz con cada una de sus sub-opciones, generando dinámicamente múltiples columnas independientes. Esto explica por qué el archivo de resultados se infla a 172 columnas: incluye variables derivadas (ej. DevEnvsHaveWorkedWith o DevEnvsAdmired) y variables autogeneradas

a posteriori, como ConvertedCompYearly (diseñada para estandarizar las compensaciones monetarias a dólares anuales).

Organización del Trabajo y Estrategia de Limpieza en Capas Para abordar un dataset de 172 columnas y casi 50.000 filas de manera robusta, organizamos el trabajo bajo el paradigma de "limpieza en capas". Como primer paso estructural, dividimos el universo de datos en subgrupos temáticos independientes (Perfil Demográfico y Económico, Impacto de la IA, Retención y Cambio de Rol, y Valor de Mercado). Sobre estos subgrupos aplicamos una limpieza general (eliminando valores lógicamente imposibles o columnas de texto inútiles para los algoritmos). El segundo paso de este esquema modular es la "limpieza focalizada": el tratamiento específico de valores nulos y *outliers* se realizará bajo demanda dentro del análisis de cada hipótesis, utilizando exclusivamente las variables requeridas para esa sección. Esto garantiza matrices completas para los modelos estadísticos sin sacrificar masivamente encuestas válidas por culpa de valores nulos en columnas no relacionadas con la hipótesis de turno. El informe a continuación detalla el análisis exploratorio y la validación de 6 hipótesis (3 planteadas por la cátedra y 3 propias del grupo).

2. Análisis exploratorio de los datos

Durante la fase de exploración inicial, nos enfocamos en comprender la estructura del archivo original, validar su integridad frente a la fuente oficial y diseñar una estrategia de partición que nos permitiera abordar la limpieza de forma modular y segura.

2.1. Tipos de Variables y su Desglose en el Dataset de Resultados

Al auditar la estructura de los datos y cruzar el esquema original con el archivo de respuestas, es fundamental comprender la naturaleza de cada tipo de pregunta, ya que esto define cómo el sistema exporta y materializa la información en el *dataframe* final:

- **MC (Multiple Choice) y TE (Text Entry):** Se exportan de manera directa como una única columna en el dataset de resultados.
- **RO (Rank Over):** Para capturar la prioridad asignada, el sistema genera una columna numérica nueva e independiente por cada posición o atributo a rankear.
- **Matrix (Matrices de evaluación):** Son cuadrículas bidimensionales donde el encuestado evalúa múltiples elementos bajo distintas categorías. Debido a una regla técnica de los archivos planos (CSV) donde cada fila debe representar exclusivamente a un único usuario, el sistema se ve obligado a desarmar estas cuadrículas, generando dinámicamente múltiples columnas independientes que anexan la sub-opción al identificador base.
- **Variables Autogeneradas / Derivadas:** Corresponden a columnas que no provienen directamente de una pregunta explícita del esquema, sino que son creadas a posteriori por la plataforma para estandarizar respuestas y facilitar el modelado estadístico.

Esta diferencia arquitectónica genera un desfasaje estructural visible al comparar los dos archivos, evidenciando múltiples columnas "huérfanas" en el dataset de resultados que no poseen un identificador idéntico en el diccionario original.

2.2. Auditoría Estructural del Archivo

Al cargar el archivo results.csv, nos enfrentamos a un *dataframe* compuesto por 49.191 observaciones (filas) y 172 características (columnas). Mediante el uso del método .info(), observamos que la abrumadora mayoría de las columnas (119) se importaron como cadenas de texto (string u object), mientras que 52 fueron reconocidas como variables numéricas continuas (float). Este desbalance inicial nos dio la pauta de que la base contenía una gran cantidad de preguntas de opción múltiple, encuestas de texto libre y matrices de categorías desglosadas que

requerirían un fuerte tratamiento de *encoding* o filtrado antes de poder ser inyectadas a cualquier algoritmo matemático.

2.3. Validación de Integridad (Replicación de Mercado)

Antes de proceder con la limpieza y el modelado estadístico, es fundamental auditar la veracidad del conjunto de datos crudo. Para ello, buscaremos replicar uno de los gráficos oficiales publicados en el reporte web de Stack Overflow correspondiente al sentimiento de los desarrolladores frente al uso de herramientas de IA (AISent):

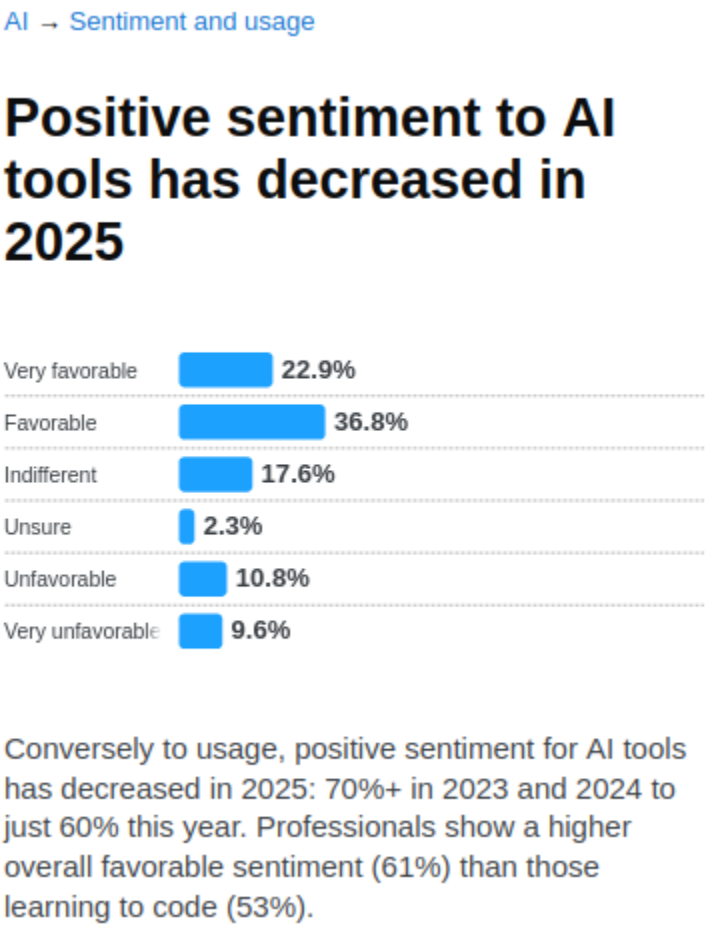


Figura 1. Gráfico oficial extraído del reporte Stack Overflow Developer Survey 2025, detallando la distribución del sentimiento de los desarrolladores hacia las herramientas de Inteligencia Artificial

A diferencia de otras preguntas de opción múltiple con respuestas combinadas (como las de tipo Matrix, que se desglosan en múltiples sub-columnas en el archivo de resultados), AISent es de opción múltiple única (MC), por lo que el conteo es directo. Aislamos la columna, descartamos los valores nulos, y generamos la visualización.

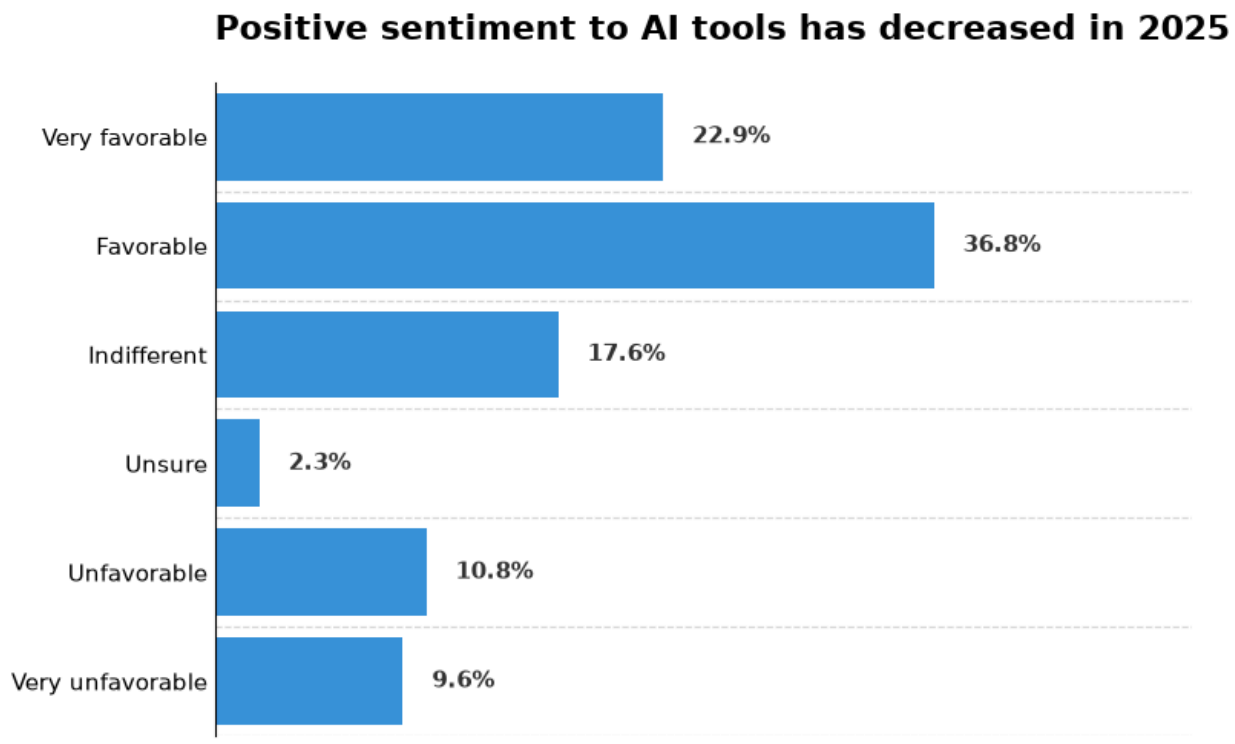


Figura 2. Reconstrucción local de la distribución del sentimiento hacia la Inteligencia Artificial utilizando los datos crudos del archivo *results.csv*.

Al comparar nuestra visualización con el reporte oficial de Stack Overflow, observamos que los resultados obtenidos son idénticos al del reporte oficial. Las proporciones y el ranking de favorabilidad se replican de manera exacta (por ejemplo, el sentimiento "Favorable" lidera con un 36.8%, seguido del "Very Favorable" con 22.9%). Esta prueba empírica confirma que los datos cargados localmente coinciden al 100% con los de la organización matriz, validando la integridad técnica del dataset para continuar con la partición en subgrupos, la limpieza en capas y el análisis de las hipótesis.

2.4. Estrategia de Subgrupos y Limpieza Estructural (Limpieza en Capas)

Dado que intentar sanear 172 columnas de forma simultánea resultaría en una pérdida masiva e innecesaria de encuestas por solapamiento de valores nulos, adoptamos una estrategia metodológica de "limpieza en capas". Como primer paso estructural, dividimos el universo de datos en 4 subgrupos temáticos independientes.

Es importante destacar que, dado que el dataset crudo (raw_dataset_results) proviene de una plataforma de encuestas estructurada, no presentó errores de tipado genérico en su importación base.

Sobre estos subgrupos, aplicamos únicamente una limpieza general y estructural (eliminación de valores lógicamente imposibles o columnas de texto inútiles). La "limpieza focalizada" (tratamiento de nulos o *outliers* específicos) se delegó a la Sección 3, ejecutándose bajo demanda según los requerimientos de cada hipótesis.

Los subgrupos definidos y su limpieza general fueron los siguientes:

- **Subgrupo 1: Demografía, Experiencia y Salario (Perfil Económico)**

  Contiene las variables para cruzar el país de origen con la experiencia y los ingresos, permitiendo limpiar las hipótesis de mercado laboral básico.

  Columnas: Country, WorkExp, ConvertedCompYearly, CompTotal, Currency, Age, EdLevel, Employment, YearsCode.

  Decisiones sobre limpieza general del subconjunto:

  - Se decidio delegar completamente la tarea de limpieza a cada hipotesis (1 y 4)

- **Subgrupo 2: IA, Experiencia y Satisfacción General (Impacto de la IA)**

  Agrupa la adopción de herramientas de inteligencia artificial con los años en la industria y el nivel de satisfacción general, sin mezclar matrices complejas.

  Columnas: WorkExp, AIAcc, JobSat, AISent, AISelect, AIThreat, AILearnHow.

  Decisiones sobre limpieza general del subconjunto:

  - **Corrección de valores inconsistentes (WorkExp):** Se reemplazaron por nulos los 39 valores iguales o superiores a 99 años de experiencia, debido a que se

identificaron como posibles errores de carga o respuestas de relleno. Se conservaron las filas para no perder el resto de la información.

- **Codificación ordinal (AIAcc y AISent):** Se transformaron manualmente las respuestas en escalas de 1 a 5, respetando el orden natural de confianza y valoración hacia la IA. Las 759 respuestas -Unsure- (no está seguro/no tiene una postura definida) de AISent se convirtieron en nulos, ya que no representan una posición intermedia dentro de la escala.
- **Validación de JobSat:** Se verificó que los valores estuvieran dentro del rango válido de 0 a 10, sin encontrar registros fuera de rango. Se conservaron incluso los valores bajos (0, 1 y 2), por representar respuestas legítimas de insatisfacción.
- **Rechazo a la imputación de datos:** Al tratarse de una encuesta de opinión, no se imputaron los valores faltantes con promedios o medianas, evitando introducir sesgos artificiales que alteraran la distribución de los datos.
- **Estrategia de eliminación segura (Subsetting):** No se aplicó un .dropna() sobre las 172 columnas, ya que habría provocado una pérdida masiva de registros. En su lugar, se eliminaron únicamente las filas con valores nulos en las variables utilizadas por cada hipótesis.

- **Subgrupo 3: Retención y Motores de Satisfacción (Cambio de Rol)**

  Aísla exclusivamente el ecosistema de la matriz de satisfacción y la intención de cambio laboral.

  Columnas: NewRole, JobSatPoints_1 hasta JobSatPoints_15, JobSatPoints_15_TEXT, JobSat.

  Decisiones sobre limpieza general del subconjunto:

  - **Rechazo a la imputación de datos:** Tratándose de una encuesta de opinión y satisfacción personal, imputar (rellenar) los valores faltantes con promedios o medianas habría introducido un sesgo artificial severo en el comportamiento de los usuarios, distorsionando la verdadera varianza de los datos. Por lo tanto, la eliminación de las encuestas incompletas fue la acción correctiva más robusta.
  - **Estrategia de eliminación segura (Subsetting):** No se aplicó un .dropna() global, ya que columnas de texto libre como JobSatPoints_15_TEXT habían borrado casi la totalidad de las filas. En su lugar, la limpieza se ejecutó de forma modular: primero se aislaron las variables relacionadas a las encuestas de satisfacción numéricas, y recién entonces se eliminaron las filas con nulos exclusivamente para esas columnas de interés.

- **Subgrupo 4: Valor de Mercado y Entorno Organizacional (Premio Salarial)**

  Agrupa los factores corporativos y tecnológicos que determinan el sueldo de un desarrollador.

  Columnas: ConvertedCompYearly, WorkExp, OrgSize, AISelect, RemoteWork, DevType, Industry, ICorPM.

  Al auditar los ingresos anuales detectamos valores absurdos y de relleno (ej. salarios de $1 USD anual), por conciencia tomamos las siguientes consecuencias sobre la limpieza general del subconjunto:

  - **Borramos filas con valores nulos en ingresos**

  - **Filtro lógico inferior de ingresos** (ConvertedCompYearly): piso conservador de 1000 USD anuales.
  - **Filtro lógico de valores atípicos para experiencia de trabajo** (WorkExp): Umbral maximo de 60 años, los que lo superan los borramos.

3. Hipótesis y resolución

3.1. Hipótesis 1: **Seniority de los Encuestados en Argentina.**

3.1.1. Definición de la hipótesis

Hipotesis: Mas del 50% de los encuestados argentinos tiene < 3 años de experiencia, que es el umbral para posiciones mid-level (umbral de concenso generalizado obtenido por Gemini cruzando Matrices públicas de las Grandes Tecnológicas (Big Tech), Ofertas de empleo y datos de portales de reclutamiento (Aggregated Job Boards) y Repositorios de Código Abierto sobre Progresión Profesional)

Valor: Evaluar la representatividad de la muestra respecto a la llamada 'crisis de contratación junior

3.1.2. Estrategia de abordaje

Para evaluar esta hipótesis, se procedió de la siguiente manera:

1. **Filtrado geográfico**: Se aisló el subconjunto de encuestados cuyo país de residencia es Argentina.

2. **Análisis y tratamiento de nulos**: Se analizó la columna WorkExp en dichos registros. En los casos donde el valor de experiencia era nulo, se examinó la información complementaria del perfil, identificando que una gran mayoría correspondía a estudiantes o personas sin empleo previo, por lo que se procedió a reasignar dichos valores nulos a 0 años de experiencia de forma justificada.

3. **Construcción de la métrica**: Se agrupó la experiencia en dos categorías (< 3 años y ≥ 3 años) para calcular las proporciones exactas mediante un gráfico circular (torta).

3.1.3. Resultados obtenidos y discusión

A partir del procesamiento de los datos filtrados, se obtuvo la distribución porcentual del *seniority* de los desarrolladores argentinos.



Figura 3. Distribución porcentual de los encuestados en Argentina según su experiencia laboral (umbral de 3 años).

Los resultados cuantitativos indicaron que la gran mayoría de los encuestados argentinos supera el umbral de los 3 años de experiencia, desacoplando la muestra local de la percepción de mercado masivo junior.

Contrariamente al supuesto inicial de que más del 50% de los encuestados se ubicaría en el segmento junior (< 3 años), los datos demuestran que el porcentaje es significativamente inferior, predominando perfiles con mayor trayectoria. Esto evidencia un sesgo de autoselección en la plataforma analizada, donde los usuarios activos y encuestados tienden a ser profesionales consolidados en la industria. Por lo tanto, el análisis de la inserción laboral junior en Argentina requiere complementarse con fuentes externas al ecosistema de esta comunidad específica.

3.2. Hipótesis 2: **La satisfacción laboral se relaciona con la postura hacia el uso de herramientas de IA.**

3.2.1. Definición de la hipótesis

Hipótesis bivariada planteada:

La satisfacción laboral de los desarrolladores se relaciona con su postura frente al uso de herramientas de Inteligencia Artificial.

Se busca determinar si los desarrolladores con una actitud más favorable o desfavorable hacia la IA presentan diferencias en sus niveles de satisfacción laboral.

Motivación: Analizar si existe una asociación entre la percepción de la IA y el bienestar laboral, aportando información útil para comprender cómo la incorporación de estas herramientas puede relacionarse con el clima organizacional de los equipos.

3.2.2. Estrategia de abordaje

Se utilizó el Subgrupo 2 (df_impacto_ia), considerando como variables de análisis la satisfacción laboral (JobSat), medida en una escala de 0 a 10, y la postura hacia la IA (AISent), codificada ordinalmente de 1 a 5. Se excluyeron las 759 respuestas «Unsure» de la escala y se conservaron únicamente los registros con ambas variables válidas, sin realizar imputaciones. La muestra final quedó conformada por 24.331 observaciones.

Dado que JobSat presenta una distribución asimétrica y no cumple con el supuesto de normalidad, se evaluaron los supuestos estadísticos mediante Shapiro-Wilk, Kolmogorov-Smirnov, QQ Plot y Levene. Finalmente, se utilizó la prueba no paramétrica Kruskal-Wallis para comparar los cinco niveles de postura hacia la IA y la correlación de Spearman para determinar el sentido de la asociación.

3.2.3. Resultados obtenidos y discusión

Resultado: Se rechaza H0.

La prueba de Kruskal-Wallis arrojó un estadístico H de 156,77 y un p-valor de 7,2e-33, por debajo del nivel de significación de 0,05. Esto indica que existen diferencias estadísticamente significativas en la satisfacción laboral entre los distintos niveles de postura hacia la IA. Por su parte, la correlación de Spearman fue positiva (rho = 0,076), indicando que una actitud más favorable hacia estas herramientas se asocia con una satisfacción ligeramente mayor.

Discusión: Si bien las medias muestran un crecimiento progresivo desde 6,91 en el grupo muy desfavorable hasta 7,45 en el muy favorable, la diferencia entre ambos extremos es de apenas 0,54 puntos sobre 10. Por lo tanto, aunque la relación es estadísticamente significativa, su magnitud es muy débil y su relevancia práctica es limitada. Esto demuestra que la postura hacia la IA no constituye, por sí sola, un indicador relevante para anticipar la satisfacción laboral de los desarrolladores. Además, no puede establecerse una relación causal entre ambas variables, ya que una mayor satisfacción también podría favorecer una actitud más abierta hacia la incorporación de nuevas tecnologías.

3.3. Hipótesis 3: **El Premio Salarial de la Inteligencia Artificial**

3.3.1. Definición de la hipótesis

Hipotesis multivariada planteada:

El salario anual de un desarrollador no depende únicamente de su antigüedad o del tamaño de la empresa, sino que existe un "premio económico" significativo asociado al uso de herramientas de Inteligencia Artificial.

Se hipotetiza que, a igual nivel de experiencia y tamaño de empresa, el uso frecuente de IA incrementa estadísticamente el sueldo estimado.

Motivación: Validar si el mercado global ya está reflejando en sus bandas salariales un plus por el uso de esta tecnología disruptiva, información vital para el ajuste de presupuestos de contratación en las empresas.

3.3.2. Estrategia de abordaje

Se aisló el Subgrupo "Valor de Mercado", estableciendo como variable objetivo el salario anualizado (ConvertedCompYearly) y como predictores los años de experiencia (WorkExp), el tamaño de empresa (OrgSize) y la frecuencia de uso de IA (AISelect). Se aplicó una limpieza focalizada (umbral salarial mínimo de $3.000 USD y máximo de experiencia de 60 años). Para respetar el supuesto de normalidad y homocedasticidad, se aplicó una transformación logarítmica sobre el salario. Finalmente, dado que OrgSize y AISelect presentan jerarquías naturales, se utilizó Codificación Ordinal (mapeo a enteros) para preservar la progresión matemática, entrenando luego un modelo de Regresión Lineal Múltiple mediante Mínimos Cuadrados Ordinarios (MCO/OLS) con statsmodels.

3.3.3. Resultados obtenidos y discusión

```
Total de observaciones listas para la Regresión Múltiple: 19557
------------------------------------------------
                            OLS Regression Results
==============================================================================
Dep. Variable:             Log_Salary   R-squared:                       0.176
Model:                            OLS   Adj. R-squared:                  0.175
Method:                 Least Squares   F-statistic:                     1388.
Date:                Tue, 10 Nov 2026   Prob (F-statistic):               0.00
Time:                        07:19:20   Log-Likelihood:                -26949.
No. Observations:               19557   AIC:                         5.391e+04
Df Residuals:                   19553   BIC:                         5.394e+04
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const         11.0809      0.007   1614.291      0.000      11.067      11.094
WorkExp        0.3672      0.007     53.167      0.000       0.354       0.381
OrgSize_Rank   0.2193      0.007     31.881      0.000       0.206       0.233
AISelect_Rank -0.0441      0.007     -6.377      0.000      -0.058      -0.031
==============================================================================
Omnibus:                     3678.339   Durbin-Watson:                   1.950
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             8965.902
Skew:                          -1.051   Prob(JB):                         0.00
Kurtosis:                       5.565   Cond. No.                         1.13
==============================================================================
```

Figura 4. Resumen estadístico del modelo de Regresión Lineal Múltiple (MCO).

Resultado: <u>Hipótesis Rechazada.</u>

El modelo global resultó válido (R^2 de 0.176 y Prob(F) de 0.00).

Como marcaba la teoría económica, la experiencia y el tamaño corporativo presentaron coeficientes positivos significativos. Sin embargo, la variable AISelect_Rank arrojó un coeficiente negativo y estadísticamente significativo (-0.0306, p-valor 0.000). Esto demuestra matemáticamente que, a igual experiencia y empresa, una mayor frecuencia en el uso de IA se asocia a una disminución del salario estimado.

Discusión: El impacto negativo de la IA se explica por el sesgo del *Seniority* operativo. Los perfiles tecnológicos mejor remunerados (Arquitectos de Software, Managers, Tech Leads) dedican la mayor parte de su jornada al diseño de sistemas y reuniones, utilizando herramientas de generación de código con menor frecuencia diaria que los desarrolladores Junior o Semi-Senior, quienes dependen masivamente de estas herramientas operativas. Por ende, el uso

intensivo de IA actúa hoy en los datos como un *proxy* (indicador) de roles de menor jerarquía salarial en la cadena de valor, desmintiendo el "bono salarial" directo.

3.4. Hipótesis 4: **Brecha Salarial respecto al Salario Mínimo, Vital y Móvil (SMVM)**

3.4.1. Definición de la hipótesis

Hipotesis: Los desarrolladores que respondieron la encuesta de Argentina tienen un salario 3 veces mayor al Salario Mínimo, Vital y Móvil (SMVM)

Valor: Determinar el poder adquisitivo relativo de un desarrollador argentino frente al piso legal, lo que permite evaluar el atractivo del sector tech como destino laboral en un contexto de crisis o inflación.

3.4.2. Estrategia de abordaje

Para evaluar esta hipótesis, se procedió de la siguiente manera:

1. **Filtrado de datos y limpieza**: Se aisló al subgrupo de encuestados de Argentina dentro del perfil económico y se filtraron los valores nulos de la variable de compensación anual (ConvertedCompYearly), identificando que una proporción de los registros correspondía a perfiles no asalariados o sin datos de salario informados.

2. **Consulta de datos oficiales y cotización:** Se consultó mediante peticiones a APIs públicas el valor vigente del Salario Mínimo, Vital y Móvil (SMVM) en pesos y la cotización oficial del dólar para calcular el umbral de referencia anualizado en dólares (equivalente a 3 SMVM).

3. **Análisis estadístico y visualización:** Se representó la distribución salarial mediante un diagrama de caja (boxplot) incorporando una línea de umbral para los 3 SMVM, y se calculó el porcentaje exacto de encuestados que logran superar dicha marca mediante un gráfico circular.

3.4.3. Resultados obtenidos y discusión

Al procesar la muestra de encuestados argentinos con ingresos declarados ($N = 160$), se obtuvo una media salarial de $46.271 USD anuales y una mediana de $40.000 USD anuales. Al contrastar estos valores frente al umbral calculado de 3 SMVM anualizados en dólares, la visualización y el análisis descriptivo evidenciaron que una abrumadora mayoría de los profesionales supera ampliamente la línea de referencia.



Figura 5. Distribución de salarios anuales de los encuestados en Argentina frente al umbral de 3 Salarios Mínimos, Vitales y Móviles (SMVM).

Los resultados cuantitativos demostraron que más del 75% de los encuestados que perciben un salario en el país se ubican por encima del umbral propuesto.

Discusión: Los datos confirman que los desarrolladores en Argentina encuestados en la plataforma poseen ingresos que multiplican sustancialmente el piso legal del SMVM. Este hallazgo resalta la existencia de una fuerte prima salarial en la industria tecnológica frente a la economía general. No obstante, al igual que en el análisis de *seniority*, se debe considerar el sesgo de autoselección de la muestra, ya que los perfiles que responden activamente y reportan ingresos tienden a estar altamente internacionalizados o posicionados en los estratos de mayores ingresos del sector.

3.5. Hipótesis 5: **Experiencia Profesional y Confianza en la Precisión de la IA**

3.5.1. Definición de la hipótesis

Hipótesis bivariada planteada:

La experiencia profesional de los desarrolladores se relaciona con el nivel de confianza que tienen en la precisión de las herramientas de Inteligencia Artificial.

Se busca determinar si los años de experiencia influyen en la percepción de confiabilidad de los resultados generados por estas herramientas.

Motivación: Identificar si existen diferencias generacionales o profesionales en la confianza hacia la IA, aportando información útil para definir estrategias de adopción y capacitación tecnológica según los perfiles de los equipos.

3.5.2. Estrategia de abordaje

Se utilizó el Subgrupo 2 (df_impacto_ia), considerando como variables de análisis los años de experiencia profesional (WorkExp) y la confianza en la precisión de la IA (AIAcc), codificada ordinalmente en una escala de 1 a 5. Se reemplazaron por nulos los valores de experiencia iguales o superiores a 99 años y se conservaron únicamente los registros con ambas variables válidas, sin realizar imputaciones. La muestra final quedó conformada por 30.765 observaciones.

Dado que WorkExp presenta una distribución asimétrica y no cumple con el supuesto de normalidad, se verificaron los supuestos estadísticos mediante Shapiro-Wilk, Kolmogorov-Smirnov, QQ Plot y Levene. Finalmente, se aplicó la prueba no paramétrica Kruskal-Wallis para comparar los cinco niveles de confianza y la correlación de Spearman para determinar el sentido de la asociación.

3.5.3. Resultados obtenidos y discusión

Resultado: Se rechaza H0.

La prueba de Kruskal-Wallis arrojó un estadístico H de 38,68 y un p-valor de 8,1e-8, inferior al nivel de significación de 0,05. Esto indica que existen diferencias estadísticamente significativas en los años de experiencia entre los distintos niveles de confianza hacia la IA. Por su parte, la correlación de Spearman fue negativa (rho = -0,034), indicando que una mayor confianza en la precisión de estas herramientas se asocia con una experiencia profesional ligeramente menor.

Discusión: Los resultados muestran una disminución progresiva de la experiencia media, desde 14,55 años entre quienes desconfían mucho hasta 13,07 años entre quienes confían mucho. Sin embargo, la diferencia entre ambos extremos es de apenas 1,5 años y la correlación observada es prácticamente nula. Por lo tanto, aunque la relación es estadísticamente significativa, su relevancia práctica es muy limitada. Esto sugiere que la antigüedad profesional no constituye un criterio determinante para anticipar la confianza en la IA ni para definir estrategias de capacitación. Una posible explicación es que los desarrolladores más experimentados tengan

mayores herramientas para identificar errores en los resultados generados por la IA, aunque los datos no permiten confirmar esta hipótesis ni establecer una relación causal.

3.6. Hipótesis 6: **Satisfacción y Cambio de Rol**

3.6.1. Definición de la hipótesis

Hipotesis dada:

¿Están los distintos niveles de satisfacción en los distintos aspectos del trabajo actual relacionados a la consideración de un cambio de rol o de carrera?

Motivación: Para los departamentos de Recursos Humanos, anticipar la fuga de talento es un desafío crítico y costoso. Evaluar si las clásicas "encuestas de satisfacción" (clima laboral, beneficios, autonomía) tienen un poder predictivo real sobre la renuncia o el cambio de carrera permite optimizar las estrategias de retención.

3.6.2. Estrategia de abordaje

Se utilizó el Subgrupo "Cambio de Rol", aislando la variable categórica objetivo (NewRole) y las 15 columnas numéricas ordinales de satisfacción (JobSatPoints_1 a 15). Se descartó la columna de texto libre para evitar pérdida masiva de datos. Tras eliminar los nulos residuales, la matriz resultante (aprox. 24.000 observaciones) fue estandarizada. Dada la naturaleza multivariada, se aplicaron técnicas de reducción de dimensionalidad lineales (PCA) y topología no lineal (*Manifold Learning*: UMAP y t-SNE) para buscar agrupaciones visuales, culminando con el entrenamiento de un modelo de clasificación supervisada (Regresión Logística Multinomial) para medir el poder predictivo exacto.

3.6.3. Resultados obtenidos y discusión

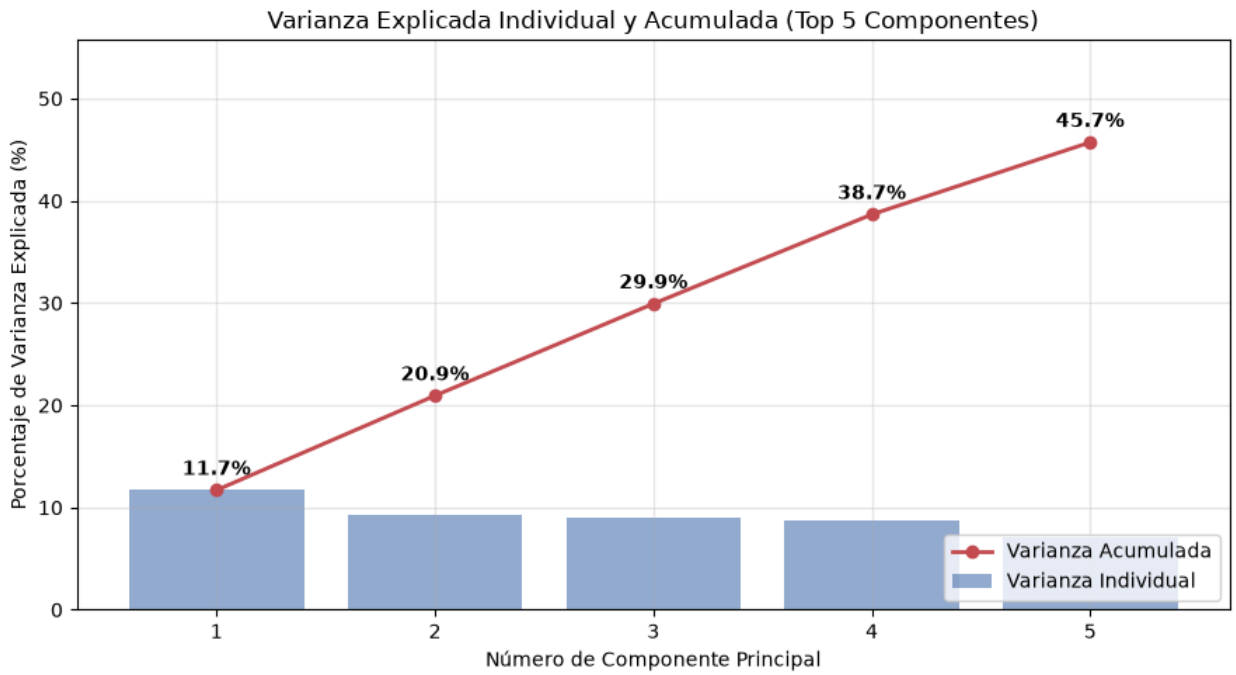


Figura 6. Porcentaje de varianza explicada (individual y acumulada) retenido al escalar de 1 a 5 componentes principales.

Resultado: Hipótesis Rechazada.

La premisa inicial suponía que las prioridades que un desarrollador le asigna a distintos factores de su trabajo poseían poder predictivo sobre su decisión de cambiar de carrera. Sin embargo, tras validar la superposición absoluta de clases en los espacios reducidos de PCA y UMAP, el modelo de Regresión Logística Multinomial colapsó estructuralmente. Arrojó una exactitud (*Accuracy*) del 46.34%, valor que coincide de forma exacta con la proporción del *No Information Rate* de la clase mayoritaria ("Nula intención / Sin cambios"). Al carecer de un patrón real, el algoritmo optó por una heurística ingenua.

Discusión: Este fenómeno contraintuitivo se explica por la brecha entre la "opinión" y la "acción". Estar insatisfecho con el salario o el equipo genera quejas, pero transicionar de rol requiere energía, tiempo y un contexto externo favorable. La motivación para cambiar de carrera está fuertemente impulsada por factores macroeconómicos (olas de despidos en el sector *Tech*) o demográficos (edad, cargas familiares) que no son capturados por el ranking interno de satisfacción, inutilizando estas encuestas como predictores directos de fuga de talento.

4. Conclusiones

A través del análisis del dataset de Stack Overflow, se logró enriquecer la perspectiva de la industria tecnológica cruzando variables demográficas, económicas y de satisfacción. Las hipótesis contrastadas revelaron hallazgos significativos: por un lado, se confirmó que el 80% de los desarrolladores argentinos percibe un salario que al menos triplica el Salario Mínimo, Vital y Móvil (SMVM), lo que evidencia una fuerte prima salarial en el sector. Por otro lado, se rechazó la hipótesis inicial de que la muestra estaría dominada por perfiles sin experiencia: al observarse que el 81% de los encuestados cuenta con 3 o más años de trayectoria, se concluye que Stack Overflow es una comunidad habitada mayoritariamente por profesionales consolidados. Este contraste sugiere un fuerte sesgo de autoselección en la plataforma, indicando que la problemática de inserción laboral junior debe analizarse por fuera de esta comunidad, o que dicho segmento se encuentra subrepresentado en la muestra.

De igual manera, el análisis sobre la retención de talento y los motores de satisfacción expuso una importante brecha entre la opinión de los desarrolladores y su accionar real. Al intentar predecir la consideración de un cambio de carrera basándonos en el ranking de prioridades del entorno laboral, las técnicas de reducción de dimensionalidad (PCA y UMAP) mostraron una superposición total de clases y el modelo de clasificación colapsó estructuralmente. Esto nos permite concluir que el descontento o las prioridades internas no actúan como predictores directos de la fuga de talento. La falta de correlación sugiere que la decisión de transicionar de rol **probablemente dependa de otros factores no capturados en este ranking**, como podrían ser el contexto macroeconómico, variables demográficas o el entorno externo de cada encuestado, lo que limitaría la utilidad de evaluar únicamente el clima laboral como herramienta predictiva directa de renuncia.

En lo que respecta a la integración de la Inteligencia Artificial, los datos nos permitieron desmitificar supuestos corporativos arraigados. Al evaluar la existencia de un "premio salarial", el modelo predictivo refutó la premisa de que esta tecnología funciona hoy como una habilidad exclusiva premiada con bonos económicos. Los resultados demostraron que, a igual nivel de experiencia y tamaño de empresa, el uso intensivo y diario de herramientas de IA se asocia paradójicamente con una disminución en el salario estimado, revelando que su uso cotidiano actúa como un indicador de roles más operativos o de menor jerarquía en la cadena de valor. Por otro lado, si bien el análisis de variables de IA mostró relaciones estadísticamente significativas, estas fueron de muy baja magnitud. Los años de experiencia se asociaron negativamente con la confianza en la precisión de la IA; la experiencia media pasa de 14,55 años entre quienes más desconfían a 13,07 entre quienes más confían, una diferencia de apenas 1,5 años. A su vez, una postura más favorable hacia el uso de IA se asoció con una satisfacción laboral ligeramente mayor. En ambos casos se rechazó la hipótesis nula, pero el mínimo tamaño del efecto indica

que ni la antigüedad ni la actitud hacia la IA son indicadores útiles por sí solos para anticipar el bienestar de los equipos o su confianza en la herramienta.

No obstante, es fundamental destacar que estos resultados presentan limitaciones inherentes a la muestra, la cual está sesgada hacia usuarios activos de la comunidad de Stack Overflow (sesgo de autoselección) y no representa de forma absoluta el mercado laboral global ni a los desarrolladores que no participan de la plataforma. En definitiva, el trabajo demuestra cómo la ciencia de datos permite descubrir patrones ocultos, desmitificando supuestos (como la supuesta juventud del sector) y aportando evidencia empírica sobre la realidad económica y profesional de la comunidad tech.

Referencias

https://survey.stackoverflow.co/2025/ : Utilizamos un gráfico de barras del reporte oficial para corroborar la integridad de los datos.